Relatório Técnico - HealthSearch: Motor de Busca Híbrido (BM25 + Semântico + RRF)

Equipe: Bruno Cavalcante, Matheus Calixto, Miguel Porto | **Disciplina:** Tendências em Ciência da Computação - RI/PLN | **Prof. Me.** Ricardo Roberto de Lima

1. Arquitetura da Solução

Visão geral. O HealthSearch foi implementado em Python com Streamlit e executa um pipeline de quatro fases sobre um corpus fixo de 6 diretrizes médicas.

Fase 1 - Pré-processamento (TextProcessor): normalização para minúsculas, remoção de caracteres especiais preservando hífens e remoção de stopwords em português via NLTK.

Fase 2 - Motor Léxico (BM25Okapi): ranking via rank_bm25, com k1 (0-3; padrão 1,2) e b (0-1; padrão 0,75) recalculados pelos sliders.

Fase 3 - Motor Semântico (SentenceTransformer + FAISS): all-MiniLM-L6-v2 gera embeddings; vetores normalizados em L2 são indexados em IndexFlatIP.

Fase 4 - Fusão RRF: Score_RRF(D) = $\alpha \cdot [1/(k+\text{Rank_BM25})] + (1-\alpha) \cdot [1/(k+\text{Rank_Semântico})]$, com k=60 e α ajustável. Opcionalmente, os Top-3 passam por Cross-Encoder.

A interface apresenta 5 abas: Matriz Comparativa, Léxico, Semântico, Híbrido RRF e Resultado Final.

2. Comparação de Ranks - Estudo de Caso

Na consulta **"ataque cardíaco"**, o BM25 atribui score zero a todos os documentos; a componente semântica recupera documentos relacionados e o RRF preserva esse ganho de cobertura.

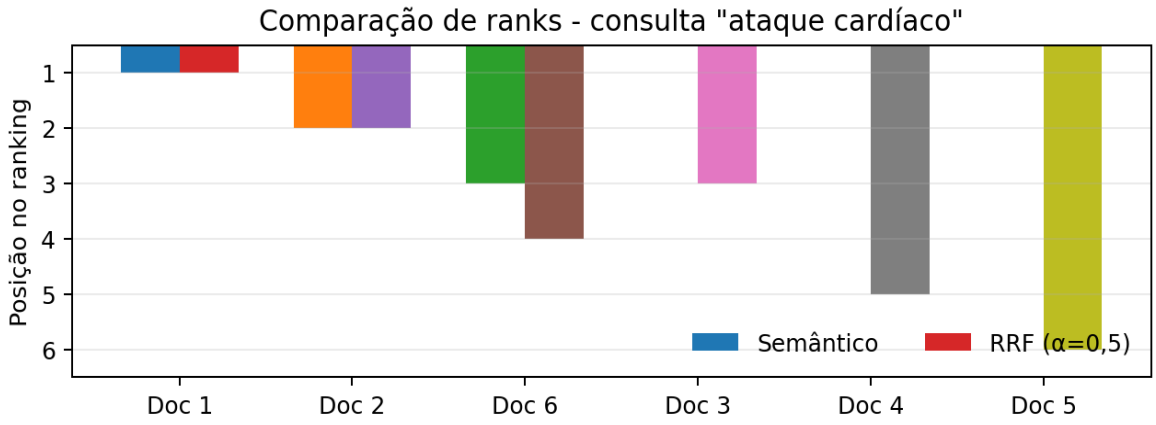


Figura 1 - Comparação visual dos ranks semântico e RRF; no BM25, todos permanecem empatados (score 0).

Documento	Rank BM25	Rank Semântico	Rank RRF (α=0,5)
Doc 1 - Emergência ECG	empatado (0)	1º	1º
Doc 2 - Farmacologia Cardíaca	empatado (0)	2º	2º
Doc 6 - UTI Geral	empatado (0)	3º	4º
Doc 3, 4, 5	empatado (0)	sem match	3º, 5º, 6º

3. Divisão de Tarefas da Equipe

Integrante	Responsabilidade
Bruno Cavalcante	Elaboração e organização do relatório técnico, documentação da arquitetura da solução e análise/apresentação da comparação de ranks, com auxílio de ferramentas de Inteligência Artificial.
Matheus Calixto	Desenvolvimento e implementação do código da solução, incluindo ajustes e testes de funcionamento, com auxílio de ferramentas de Inteligência Artificial.
Miguel Porto	Apoio tanto no desenvolvimento e revisão do código quanto na elaboração e revisão do relatório técnico.